

# Influence de l'Echantillonnage sur la Distance de Wasserstein Empirique

June 7, 2023

## Semaine 5 du 7 Juin au 14 Juin

Soit  $X_1, \dots, X_n$  réalisation i.i.d d'une probabilité  $\mu_1 \in \mathcal{P}_2(\mathbb{R}^d)$ . On note  $\hat{\mu}_1^n = \frac{1}{n} \sum_{i=1}^n \delta_{X_i}$  la réalisation empirique de  $\mu_1$ . Cette semaine, on s'intéresse à la distance  $W_2^2(\mu_1, \hat{\mu}_1^n)$ . Notamment, on sait que:

$$W_2^2(\mu_1, \hat{\mu}_1^n) \xrightarrow{n \rightarrow \infty} 0 \quad (1)$$

Cette propriété vient du fait que  $\hat{\mu}_1^n$  converge faiblement vers  $\mu_1$  et donc la distance de Wasserstein converge vers 0.

Soit  $\epsilon > 0$ , on va chercher à savoir le nombre  $n$  (c.a.d. la quantité de réalisation i.i.d) nécessaire à ce que:

$$W_2^2(\mu_1, \hat{\mu}_1^n) < \epsilon \quad (2)$$

Cette quantité  $n$  dépend de plein de paramètres telque la dimension, l'existence de moment pour la distributions,...

De manière général, on cherche à écrire:

$$W_2^2(\hat{\mu}_1^n, \mu_1) \leq \phi(n, d) \quad (3)$$

avec  $\phi$  une fonction décroissante en  $n$  et qui tend vers 0 avec  $n$ .

On écrit  $W_2^2(\hat{\mu}_1^n, \mu_1) \lesssim \phi(n, d)$  quand il y a une constante  $C > 0$  telque  $W_2^2(\hat{\mu}_1^n, \mu_1) \leq C\phi(n, d)$ .

Finalement, on appelle vitesse de convergence la quantité:

$$W_2^2(\hat{\mu}_1^n, \mu_1) \quad (4)$$

et sample complexity la quantité:

$$|W_2^2(\hat{\mu}_1^n, \hat{\mu}_2^n) - W_2^2(\mu_1, \mu_2)| \quad (5)$$

où  $\hat{\mu}_2^n$  est une réalisation empirique de  $\mu_2$  avec  $n$  atomes.

### Lecture.

- Partie 8 Introduction et partie 8.4.1 (Rates for OT) [PC<sup>+</sup>19], pour une vue d'ensemble du problème
- Vidéo sur la sample complexity <https://www.youtube.com/watch?v=g1Hy9z19mI0>
- On the rate of convergence in Wasserstein distance of the empirical measure [FG15]. Lire la partie 1.1, 1.2, 1.4 pour des résultats portant sur les moments des distributions
- Sharp asymptotic and finite-sample rates of convergence of empirical measures in Wasserstein distance [WB19]. Lire la partie 1,2, 4.1, 4.3 et 6. Pour des résultats de convergence avec la dimension intrinsèque et sur la concentration des estimateurs.

## Petit résumé de 1 page.

Les points clés sont:

- Estimateur plug-in
- Vitesse de convergence et sample complexity
- Concentration

## Faire quelques expérimentations avec les Notebook

- Vérifier numériquement la vitesse de convergence sur le sampling de Gaussienne et de distributions uniforme
- Vérifier le cas particulier où les distributions sont Gaussiennes et la distance de Wasserstein est calculée avec la distance de Bures
- Vérifier numériquement la concentration

## Points à réfléchir.

- Montrer que l'on peut avoir une borne sup pour la sample complexity si l'on a une borne sup pour la vitesse de convergence
- Faire un tableau à double entrée qui calcule le  $n$  nécessaire à ce que  $|W_2^2(\hat{\mu}_1^n, \hat{\mu}_2^n) - W_2^2(\mu_1, \mu_2)| < \epsilon$ , pour  $\epsilon \in \{1, 1^{-1}, 1e^{-10}\}$  et  $d \in \{2, 10, 100, 1000, 65536\}$
- De quoi dépendent les constantes  $C$  dans les équations de sample complexity?
- Faire une liste des hypothèses posées pour démontrer les résultats de sample complexity (existence de densité, distributions bornés, existence de moment)
- Les mesures Gaussiennes font-elles parties des probabilités qui respectent les hypothèses? Et les mesures uniforme sur un ensemble compact?
- Quels autres paramètres que l'existence de moment et la dimension pourraient influencer la vitesse de convergence?

## References

- [FG15] Nicolas Fournier and Arnaud Guillin. On the rate of convergence in wasserstein distance of the empirical measure. *Probability theory and related fields*, 162(3-4):707–738, 2015.
- [PC<sup>+</sup>19] Gabriel Peyré, Marco Cuturi, et al. Computational optimal transport: With applications to data science. *Foundations and Trends® in Machine Learning*, 11(5-6):355–607, 2019.
- [WB19] Jonathan Weed and Francis Bach. Sharp asymptotic and finite-sample rates of convergence of empirical measures in wasserstein distance. 2019.